https://repository.uaeh.edu.mx/revistas/index.php/investigium/issue/archive

Boletín Científico INVESTIGIUM de la Escuela Superior de Tizayuca

InvESTigium

ISSN: 2448-4830

Publicación semestral, Vol. 12, No. Especial (2026) pp-pp

"Quinto Congreso Internacional de Investigación e Innovación en Tendencias Globales y Tercer Coloquio de Posgrado en Gestión y Desarrollo de Nuevas Tecnologías"
26 – 29 de octubre de 2026

Aplicación móvil con inteligencia artificial para la planeación docente alineada al currículo oficial mexicano mediante modelos de lenguaje y recuperación aumentada por generación

AI-powered mobile application for lesson planning aligned with the official Mexican curriculum using language models and retrieval-augmented generation

Angel-Gabriel Garcia-Rivera [a], Juan-Carlos Gonzalez-Islas [b], Gildardo Godinez-Garrido [c], Kristian-Freyri Maya-Gress [d] y Jesus Vargas-Ortiz [e]*

Abstract:

Lesson planning under Mexico's New Mexican School framework (NEM 2022) requires teachers to consult several official documents, which takes time away from their students. To address this, an Android app was built for preschool and elementary school teachers; generative AI writes a first draft of each lesson plan, which the teacher can then adjust according to their own pedagogical criteria. Requests to the model are routed through Supabase Edge Functions instead of being sent from the phone, and each one is preceded by a hybrid search (semantic plus keyword) over Ministry of Public Education (SEP) documents, as part of a Retrieval-Augmented Generation (RAG) pipeline. Because the model works from those passages, the aim is for its answers to follow the official curriculum more closely and to reduce hallucinations. For textbooks and teacher's guides, only indexing metadata is kept, in accordance with Article 148, Section III, of Mexico's Federal Copyright Law. In an exploratory comparison of lesson plans from four sources (the app, a plan bank, and Gemini and ChatGPT without RAG) across six grades, the blind scores were 6.80 (app), 8.46 (plan bank), 7.90 (Gemini) and 7.94 (ChatGPT), and 7.12, 7.85, 6.78 and 6.98 once the source was known. The app stood out in personalization and scalability. The plans were also checked by hand: they matched the curriculum and cited the right pages. Seven in-service teachers tested the app in a pilot, assessed its applicability, coherence and references, and rated its usability favorably.

Keywords:

Lesson planning, generative artificial intelligence, retrieval-augmented generation, curriculum grounding, mobile application

Resumen:

Planear una clase dentro de la Nueva Escuela Mexicana (NEM 2022) implica revisar varios documentos oficiales, y esa búsqueda le resta al docente tiempo que podría dedicar a su grupo. Para ello se desarrolló una aplicación Android que ayuda a maestros de preescolar y primaria a elaborar sus planeaciones didácticas con IA generativa, sin quitarles la última palabra en lo pedagógico. Las llamadas al modelo pasan por Supabase Edge Functions. Antes de generar, un sistema RAG con búsqueda híbrida recupera fragmentos de los documentos de la SEP; con ello se busca que la respuesta quede anclada al currículo oficial y se reduzcan las alucinaciones. De los libros de texto y del docente solo se guardan metadatos de indexación, conforme al artículo 148, fracción III, de la Ley Federal del Derecho de Autor. En una comparación exploratoria de planeaciones de cuatro fuentes en seis grados (la aplicación, un banco de planeaciones, y Gemini y ChatGPT sin RAG), los promedios a ciegas fueron 6.80 (aplicación), 8.46 (banco), 7.90 (Gemini) y 7.94 (ChatGPT), y 7.12, 7.85, 6.78 y 6.98 al conocerse el origen. La aplicación destacó en personalización y escalabilidad. Al revisarlas

[b] Autor de Correspondencia, Universidad Autónoma del Estado de Hidalgo | Área Académica de Computación y Electrónica | Mineral de la Reforma | Hidalgo | México, https://orcid.org/0000-0002-2190-0660, Email: juan_gonzalez7024@uaeh.edu.mx

[a,,c,d,e] Universidad Autónoma del Estado de Hidalgo | Área Académica de Computación y Electrónica | Mineral de la Reforma | Hidalgo | México, https://orcid.org/0009-0004-4571-0361, https://orcid.org/0000-0002-7177-3815, https://orcid.org/0000-0001-8425-0960, https://orcid.org/0009-0006-6546-8319, Email: ga400926@uaeh.edu.mx, gildardo_godinez@uaeh.edu.mx, kristian_maya10493@uaeh.edu.mx, va421350@uaeh.edu.mx,

Fecha de recepción: DD/MM/2025, Fecha de aceptación: DD/MM/2025, Fecha de publicación: DD/MM/2025

DOI: https://doi.org/10.29057/est.v12iEspecial.xxxxx

manualmente, las planeaciones coincidían con el currículo y las páginas citadas eran las correctas. En la prueba piloto, siete docentes en servicio la usaron, valoraron su aplicabilidad, coherencia y referencias, y calificaron favorablemente su usabilidad.

***Palabras Clave**:*

Planeación didáctica, inteligencia artificial generativa, recuperación aumentada, currículo educativo, aplicación móvil

1. Introducción

El uso de modelos de lenguaje de gran escala (LLM) como apoyo docente ha aumentado al ritmo de la adopción de la IA generativa en la educación [1]. La literatura documenta usos en la creación de materiales, el acompañamiento de la enseñanza, la evaluación y la planificación [1]–[3]. También documenta sus problemas: no siempre son confiables, requieren revisión humana y pueden alejarse de los estándares educativos [4]–[6]. Un LLM escribe con base en lo que aprendió durante su entrenamiento y en las instrucciones que recibe; nada garantiza que el resultado respete un currículo en particular. Por ello se desarrollaron arquitecturas que consultan fuentes externas antes de generar la respuesta, como la generación aumentada por recuperación (RAG), en la que se seleccionan primero pasajes de una base documental y luego se redacta la respuesta con ellos [7], [8].

Ya existen varias plataformas que aplican IA generativa directamente a la planificación docente. Entre ellas está MagicSchool, con herramientas para preparar clases, materiales, evaluaciones y actividades diferenciadas [9]. Eduaide.AI pone el acento en recursos y actividades, con una interfaz pensada para el docente [10], y Education Copilot junta un planificador de clases con generadores de rúbricas, cuestionarios y otros materiales [11]. Shiksha Copilot, creado por Microsoft Research India, tiene un respaldo más sólido. Genera planes de clase con base en el currículo local, y en un estudio con más de mil docentes los participantes dedicaron menos tiempo a planear y a tareas administrativas [12]. El antecedente más parecido a esta propuesta es un prototipo para secundarias de Uganda que aplica RAG sobre los libros de texto oficiales para producir planeaciones apegadas al currículo; que funcione ahí muestra que esta arquitectura es viable aun con recursos limitados [13]. Cada uno de estos sistemas adapta el contenido al currículo a su manera, pero en conjunto indican que el enfoque es factible. Este trabajo lo lleva a la educación básica de México.

En México, quien planea una clase de educación básica debe apoyarse en documentos curriculares específicos: el Plan de Estudio 2022 [14] y el Programa Sintético de la fase que corresponda [15]. Un LLM que genera su respuesta solo a partir de su conocimiento general, sin apoyarse en esas fuentes curriculares, puede generar texto coherente pero desalineado con el currículo vigente, riesgo que se agrava porque ese conocimiento cambia con el tiempo y el modelo no se actualiza por sí solo [16]. Además, antes de escribir la primera línea de la planeación, el docente tiene que localizar, elegir y ordenar manualmente información repartida en varios documentos, y eso le quita tiempo. La propuesta une la recuperación de información curricular con la generación automática, pero deja en manos del docente los parámetros de su planeación: la tecnología le ahorra trabajo, no decide en su lugar.

Se justifica construir una solución especializada en lugar de usar un LLM genérico, porque no conviene depender solo del conocimiento obtenido durante su entrenamiento. Existe evidencia de que es posible generar planeaciones con ChatGPT, pero las respuestas varían de una ejecución a otra y requieren que el docente revise su pertinencia pedagógica [17]–[20]. Proporcionar al modelo acceso a documentos externos reduce esa dependencia del conocimiento paramétrico [21], [22]; no elimina la variabilidad, pero la sostiene con fuentes verificables. Por ello, aplicar RAG sobre documentación curricular atiende el problema técnico y permite, además, estudiar cómo se integran estas técnicas en un proceso real de desarrollo de software educativo, lo cual constituye una aportación adicional más allá de la solución en sí misma.

Se propone Aplicación Docente, una aplicación móvil para asistir la elaboración de planeaciones didácticas mediante RAG. Del lado del cliente se usó Flutter. En el backend está Supabase, con una base PostgreSQL a la que se le añadió pgvector [23]; esa extensión es la que guarda los vectores y permite buscar por significado. Todo lo que tiene que ver con los modelos generativos corre en el servidor. Así, las credenciales de los servicios de IA nunca llegan al dispositivo del docente. Los documentos no reciben el mismo tratamiento. Los curriculares oficiales se procesan e indexan completos para el RAG. Con los libros de texto, los del docente y los materiales de multigrado se hace otra cosa: se registran únicamente metadatos (título, página y estructura de lecciones y secciones), y el contenido no se almacena. Cada consulta se resuelve con dos búsquedas. La semántica localiza pasajes con un sentido cercano

aunque estén redactados de otra forma, y la textual localiza términos exactos que la primera podría pasar por alto. Al fusionar ambas listas, el modelo trabaja con un contexto mejor ajustado a la consulta.

El objetivo general es desarrollar y evaluar una aplicación que apoye a docentes de preescolar y primaria en la elaboración de sus planeaciones, uniendo la IA generativa con la información curricular oficial. De ahí se desprenden los siguientes objetivos específicos:

- Implementar la arquitectura de software de la aplicación;
- Construir el proceso de ingestión documental que genera y recupera representaciones vectoriales;
- Integrar el modelo generativo por medio de servicios de backend;
- Definir un flujo de captura de parámetros para que el docente construya su planeación;
- Evaluar la solución mediante una comparación exploratoria de planeaciones y una prueba piloto de usabilidad con docentes en servicio.

La evaluación buscó medir el desempeño de la solución, tanto en su funcionamiento técnico como en la percepción de quienes la usaron, de acuerdo con el diseño del estudio piloto.

Un punto central de esa evaluación fue explorar si, según los docentes, la aplicación reduce el tiempo que dedican a la carga administrativa asociada a esta tarea, en comparación con el proceso habitual.

La solución propuesta integra en una sola aplicación un LLM, un mecanismo de búsqueda de información y documentación curricular oficial, orientada a la planeación didáctica. Los documentos no se manejan todos de la misma manera: unos se indexan por completo y otros solo aportan su estructura, distinción definida desde la base de datos. Así, el modelo opera con contexto documental recuperado y con los parámetros definidos por el docente, de modo que la herramienta se concibe como complemento del juicio profesional docente y no como sustituto [5], [17]. El docente conserva la responsabilidad de las decisiones pedagógicas, mientras la aplicación organiza y presenta información recuperada de documentos oficiales.

2. Materiales y métodos

2.1 Arquitectura general y stack tecnológico

El sistema se organizó en capas que se comunicaban de forma unidireccional en lo que respecta a las credenciales de IA. El cliente se desarrolló en Flutter y se ejecutaba en el dispositivo del docente, mientras que el backend se apoyó en Supabase, que centralizó autenticación, una base de datos PostgreSQL con el corpus curricular, almacenamiento de archivos y funciones serverless en Deno y TypeScript, único componente con acceso a la clave de la API de Gemini, decisión que respondió a que un cliente móvil no es un entorno confiable para guardar secretos [24], ya que un binario de Android o iOS puede descompilarse con relativa facilidad [25]. Esto también permitió limitar a 30 las solicitudes por día, control posible solo porque todas las peticiones pasaban primero por el servidor [24]. Sobre esa misma base operó pgvector [23], que almacenó embeddings y comparó su similitud mediante algoritmos HNSW [26], haciendo posible la búsqueda semántica. Esta organización en capas y la distribución del stack tecnológico se muestran en la Figura 1.

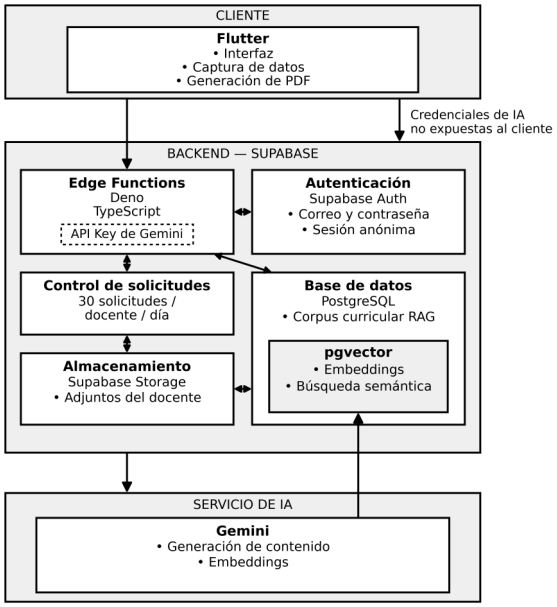


Figura 1. Arquitectura general del sistema: separación entre cliente, servicios de backend y acceso controlado a Gemini. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

2.2 Aplicación móvil y flujo de generación de planeaciones

El asistente de captura estuvo compuesto por siete pasos, usados tanto en preescolar como en primaria:

contexto del grupo, base curricular, origen del tema, metodología, información del grupo y del aula, instrumentos de evaluación, y anexos (materiales de referencia, documentos propios y, en primaria, libros de texto gratuitos según el grado). En el último paso, el docente veía un resumen que todavía podía editar antes de confirmar. Al confirmar, los datos viajaban al servidor. Ahí se verificaba quién era el docente, se recuperaban el contexto curricular y su perfil, y con todo eso se armaba la solicitud para Gemini. Gemini respondía en JSON, y antes de mostrar nada se comprobaba que vinieran todos los campos con el tipo de dato correcto [27]. Cuando faltaba un campo o venía mal formado, el docente recibía un aviso y podía volver a intentarlo. Superada esa revisión, la planeación quedaba lista para editarse, exportarse a PDF o guardarse en el historial del dispositivo. La Figura 2 resume el recorrido completo, de la captura a la validación y el resultado final.

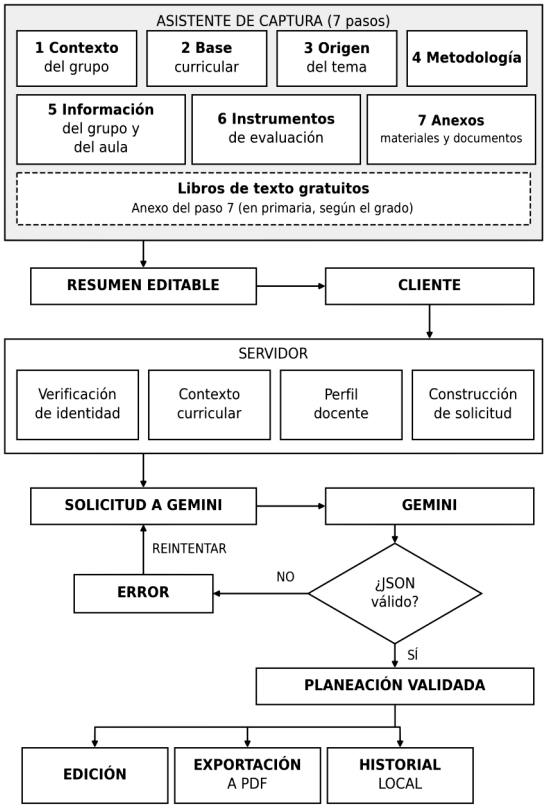


Figura 2. Flujo de captura, procesamiento y validación para la generación de planeaciones. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

Todo este flujo quedó implementado en una aplicación móvil funcional. Desde la pantalla principal se accedió a las funciones del asistente. Al iniciar una nueva planeación, el docente eligió entre preescolar y primaria, y esa elección definió desde el principio qué documentos curriculares y qué pasos del asistente se activaron. Ambas pantallas se muestran en la Figura 3.

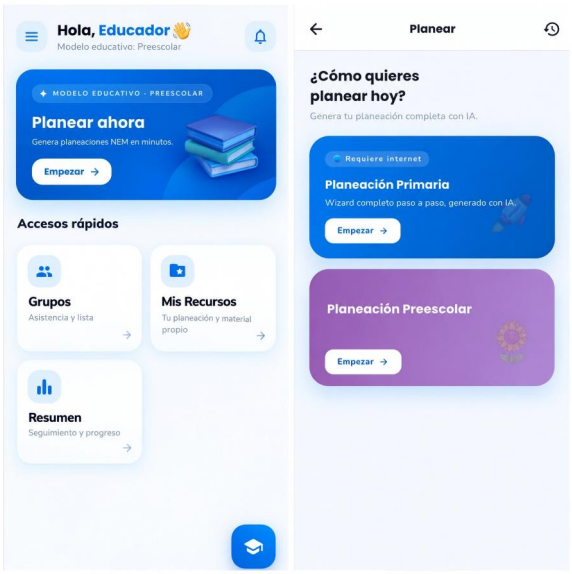


Figura 3. Pantalla principal y selección del nivel educativo al iniciar una nueva planeación. Fuente: elaboración propia, captura de la aplicación.

Durante el recorrido de los siete pasos, el docente capturó los parámetros que orientaron la generación. Un ejemplo de esta captura se observa en la sección donde se definió el tema de la planeación junto con los campos formativos y los ejes articuladores correspondientes, mientras que la sección de anexos permitió adjuntar los libros de texto gratuitos (LTG) asociados al grado y materia seleccionados. Estas pantallas pueden verse en la Figura 4.

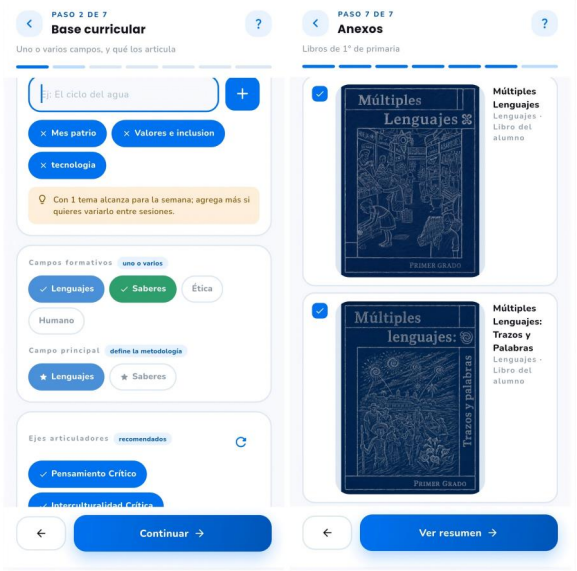


Figura 4. Selección de tema, campos formativos y ejes articuladores, y sección de anexos con libros de texto gratuitos. Fuente: elaboración propia, captura de la aplicación.

Al concluir la captura, la aplicación mostró el estado de generación de la planeación y, una vez completado el proceso, presentó el resultado final. La Figura 5 muestra ambas.



Figura 5. Pantalla de generación y planeación final generada. Fuente: elaboración propia, captura de la aplicación.

Sitio del proyecto: [https://goo.su/XomQfTS]

2.3 Base de conocimiento curricular: composición y obtención de documentos SEP

La base de conocimiento curricular contempló seis tipos de documentos: el Plan de Estudio de la NEM 2022 [14], los Programas Sintéticos por fase [15], los libros del docente por fase, los libros de texto gratuitos por grado y materia, materiales para escuelas multigrado y un sexto tipo destinado a documentos aportados por el docente, que se incorporaban al RAG mediante embeddings generados con la API de Gemini. Esta opción estuvo disponible en las pruebas de desarrollo, pero no se utilizó en la prueba con docentes. Los documentos oficiales se almacenaron en una carpeta principal de Google Drive y el sistema identificó automáticamente su tipo según la carpeta de origen, mientras que las carpetas numeradas permitieron determinar el grado cuando correspondía. Cada documento contó con un código de verificación generado a partir de sus archivos, que permitió detectar cambios desde su último procesamiento. Si no existían modificaciones, el documento se omitía, evitando consumir cuota y repetir la ingesta completa del corpus. Esta clasificación documental y el mecanismo de detección de cambios se muestran en la Figura 6.

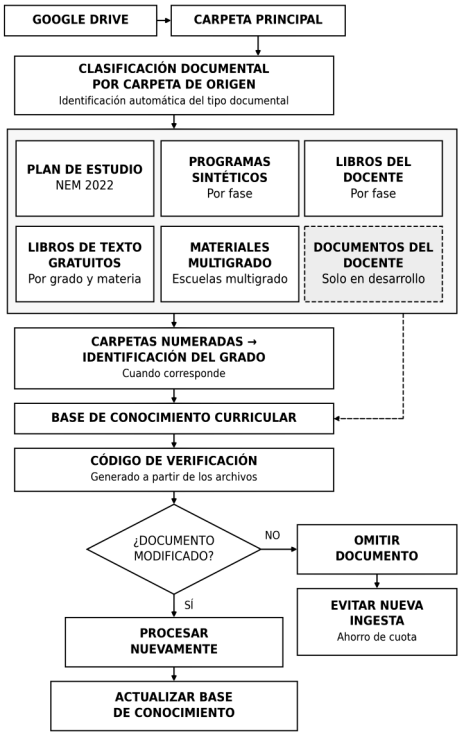


Figura 6. Composición de la base de conocimiento curricular y mecanismo de detección de cambios. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

2.4 Procesamiento documental: chunking, embeddings y base de datos vectorial

Para los documentos normativos oficiales, el texto se obtuvo desde Google Drive y se dividió en fragmentos de 1800 caracteres, con un traslape de 200 entre ellos, cortando en el último espacio disponible para evitar separar palabras [28]. Cada fragmento se transformó mediante Gemini en una representación de 768 dimensiones, reducida desde 3072 mediante Matryoshka Representation Learning [29]. El sistema diferenció entre las consultas del docente y los fragmentos de los documentos, mediante el tipo de tarea del modelo de embeddings, lo que permitió adaptar la representación a la búsqueda de información extensa a partir de preguntas breves [30]. Estas representaciones se almacenaron en pgvector y se procesaron en grupos de 20 fragmentos, guardando el avance después de cada grupo para poder continuar desde el último punto en caso de error mediante técnicas de checkpointing [31]. Este flujo de procesamiento documental y almacenamiento vectorial se muestra en la Figura 7.

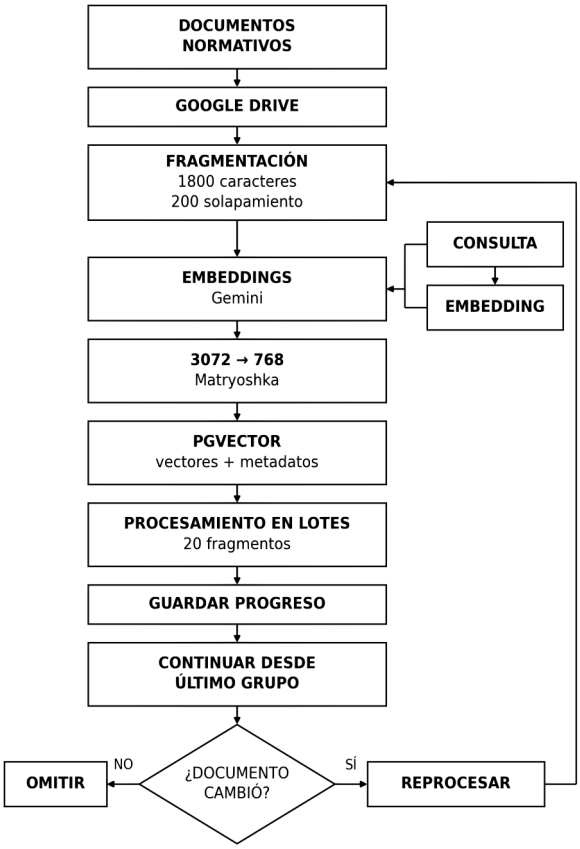


Figura 7. Flujo de procesamiento documental y almacenamiento vectorial. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

2.5 Modelo de IA generativa

El modelo utilizado en la aplicación fue Gemini Flash, seleccionado por ofrecer tiempos de respuesta y costos menores frente a variantes de mayor tamaño. Se empleó principalmente para generar la planeación completa mediante una respuesta estructurada en JSON [27] y para modificar una planeación existente a partir de las indicaciones del docente. Para estas funciones se emplearon distintos niveles de variación mediante el parámetro de temperatura [32], buscando un equilibrio entre creatividad y consistencia según el contenido requerido. La elección de Gemini Flash resultó adecuada para una aplicación interactiva, ya que permitió mantener tiempos de respuesta razonables y utilizar el mismo proveedor tanto para la generación de contenido como para los embeddings del corpus. Las funciones que cumplió Gemini Flash dentro de la aplicación se muestran en la Figura 8.

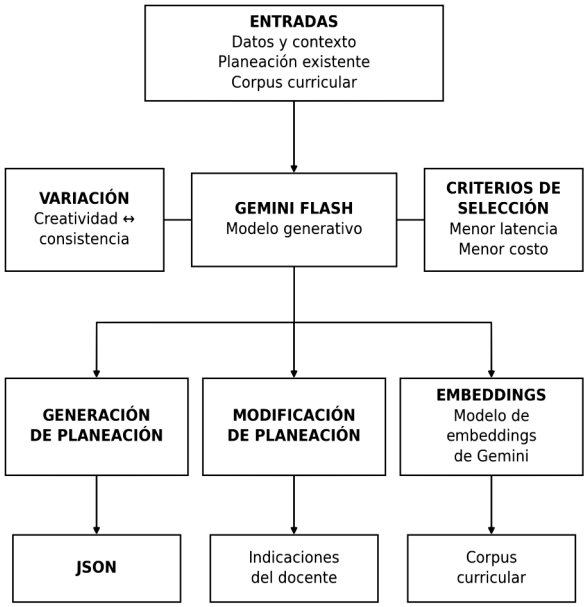


Figura 8. Funciones de Gemini Flash: generación y modificación de planeaciones, y embeddings del corpus. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

2.6 Ingeniería de prompts

El mensaje enviado a Gemini se preparó con la información necesaria para generar la planeación: una instrucción general, los datos que el docente proporcionó durante los siete pasos, la información curricular encontrada por el sistema y, cuando estaba disponible, el perfil del docente. También contenía 19 reglas que indicaban qué información considerar y cómo estructurar la respuesta, siguiendo recomendaciones planteadas en estudios sobre la elaboración de instrucciones para modelos de lenguaje [33], [34]. Una de las principales

establecía el orden en que debían utilizarse las fuentes: primero la información curricular recuperada, después el Programa Sintético, el Plan de Estudio y, solo si no se encontraba el dato, el conocimiento general del modelo, sin generar páginas, autores ni citas inexistentes. Aunque la respuesta se solicitó en formato estructurado, este no garantizaba por sí solo que fuera completamente correcta [27]. La estructura completa del prompt, sus fuentes de información y la jerarquía descrita se muestran en la Figura 9.

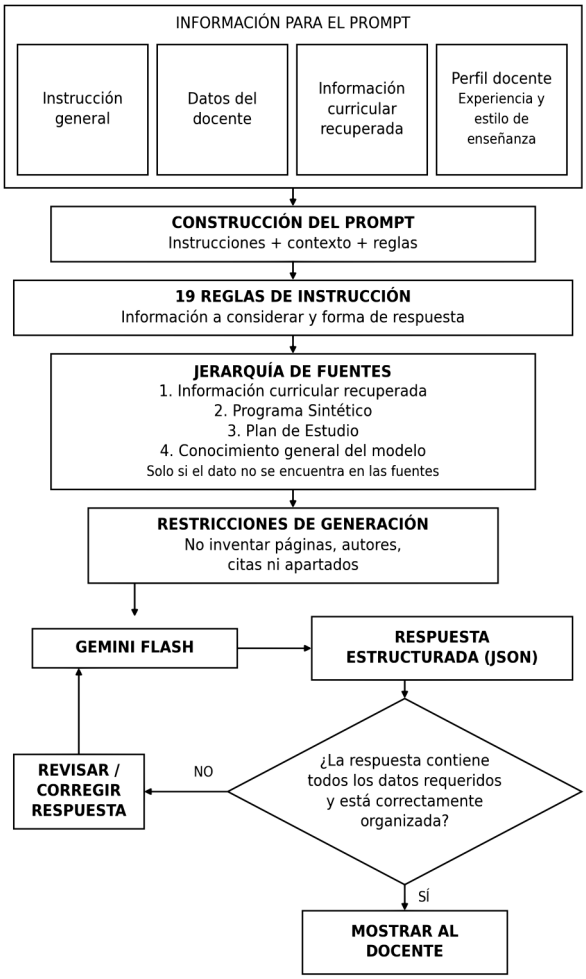


Figura 9. Estructura del prompt: fuentes de información, jerarquía de fuentes, restricciones y validación de la respuesta. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

elimina por completo. El Plan de Estudio y los Programas Sintéticos se consultaron en todas las planeaciones como base curricular. Los libros de texto gratuitos (LTG) se utilizaron únicamente cuando el tema indicado por el docente guardaba relación con alguna lección de los LTG que este había seleccionado; en caso contrario, se omitieron. Cuando se usaron, la planeación final indicó el libro y la página de origen. Además, se instruyó al modelo para clasificar cada dato generado según su nivel de respaldo [36], lo que permitió distinguir la información confirmada, sugerida y propuesta. Este mecanismo, con sus tres niveles de respaldo, se muestra en la Figura 10.

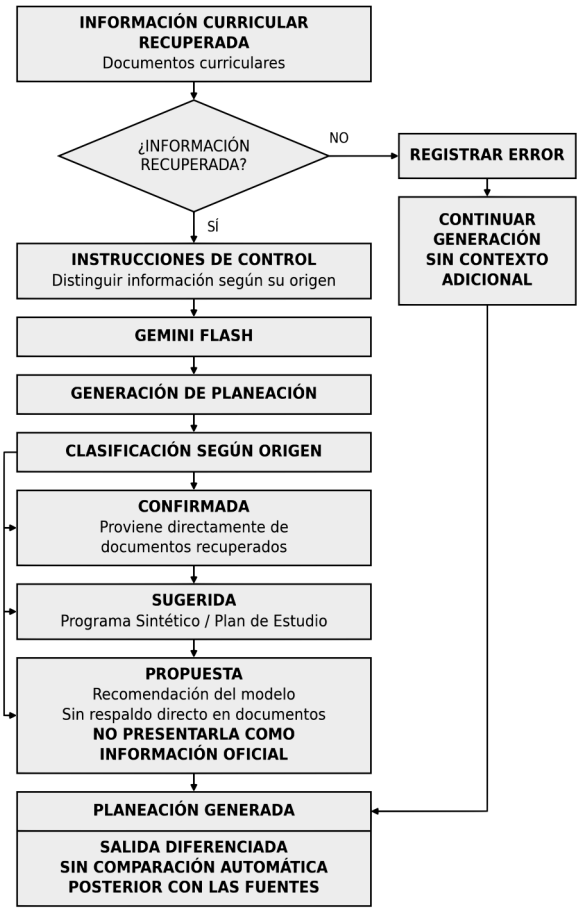


Figura 10. Mecanismo de diferenciación del origen de la información en la generación de la planeación. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura.

2.7 Validación de la información recuperada

La validación de la información recuperada se apoyó en dos mecanismos: las instrucciones dadas al modelo y una verificación manual posterior a la generación. Proporcionar información recuperada ayuda a disminuir la generación de datos incorrectos [35], aunque no lo

Para comprobar el funcionamiento de estos mecanismos, se revisaron manualmente las siete planeaciones generadas con la aplicación (una por docente participante) en tres aspectos: (a) que el contenido curricular (campos formativos, ejes articuladores, contenidos y procesos de desarrollo de aprendizaje)

correspondiera con el Plan de Estudio y los Programas Sintéticos; (b) que las referencias a LTG indicaran la página correcta; y (c) que la lección referida correspondiera con el tema de la planeación. En las siete planeaciones revisadas, el contenido curricular fue congruente con los documentos oficiales y la paginación de los LTG citados fue correcta. El contenido de las lecciones resultó similar, aunque no idéntico, al del libro, ya que estos materiales se indexaron únicamente como metadatos (sección 2.9) y el modelo no tuvo acceso a su texto. No se aplicó una comparación automática del resultado final contra los documentos oficiales ni una medición cuantitativa de fidelidad documental, lo cual queda como trabajo futuro.

2.8 Diseño del estudio piloto, participantes e instrumentos de evaluación

Se empleó un diseño descriptivo, con un cuestionario antes y otro después de la interacción con la aplicación y sin grupo de control. Participaron voluntariamente siete docentes en servicio de nivel básico en sesiones de prueba previamente programadas. Cada docente generó una planeación con la aplicación y la revisó, indicando si era aplicable a su entorno y contexto escolar, si era coherente, y si las páginas y referencias citadas existían y correspondían. Para la evaluación se armaron dos formularios en Google Forms. Al redactarlos se tomaron en cuenta las recomendaciones sobre confiabilidad y validez de las escalas Likert [37], así como las prácticas de usabilidad que se apoyan en el SUS [38]. El primero lo contestaron antes de abrir la aplicación y preguntaba qué esperaban de una herramienta digital que les ayudara a planear. Al finalizar, respondieron otro enfocado en satisfacción, usabilidad y percepción de utilidad para reducir el tiempo destinado a dicha labor. Las encuestas fueron anónimas, por lo que no se emparejaron y el análisis fue descriptivo.

La estructura del cuestionario que se aplicó antes del uso de la aplicación se muestra en la Figura 11.

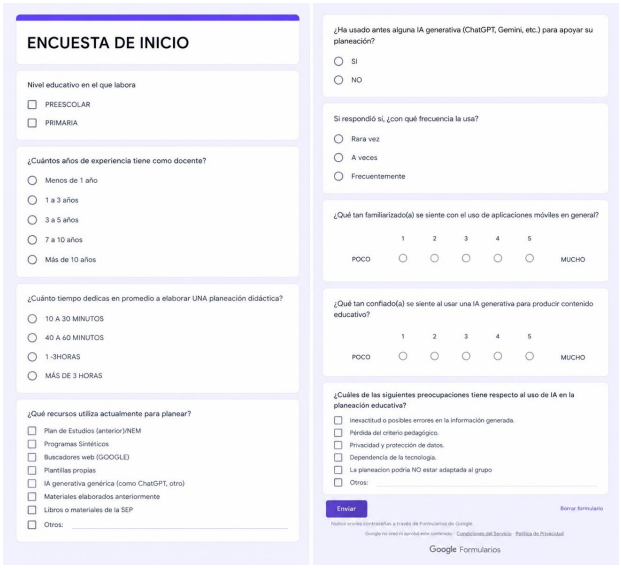


Figura 11. Cuestionario previo al uso de la aplicación. Fuente: elaboración propia, captura de Google Forms.

Al finalizar la sesión, se aplicó un segundo cuestionario centrado en satisfacción, usabilidad y percepción de utilidad, cuya estructura es presentada en la Figura 12.

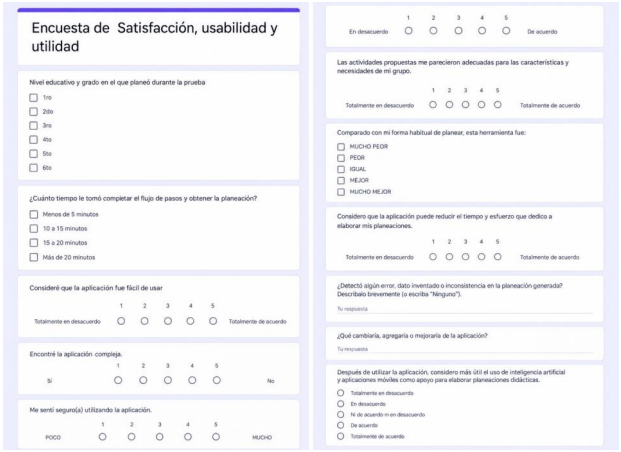


Figura 12. Cuestionario posterior a la sesión: satisfacción, usabilidad y utilidad percibida. Fuente: elaboración propia, captura de Google Forms.

2.9 Consideraciones éticas

La aplicación fue un prototipo de investigación sin fines de lucro, que se evaluó en sesiones de prueba con docentes que participaron de forma voluntaria y sin remuneración, con libertad de retirarse en cualquier momento. La escuela autorizó la prueba y se agendó una cita previa; el propósito del estudio se explicó a los participantes de manera verbal antes de iniciar la sesión y el consentimiento fue verbal, en línea con prácticas documentadas de consentimiento informado en

investigación con participantes humanos [39]. Las credenciales, el nivel educativo y los registros de práctica se almacenaron en Supabase con cifrado en tránsito y en reposo, protegidos por Row Level Security. El uso de los libros de texto, libros del docente y materiales de multigrado de la SEP se sustentó en el artículo 148, fracción III, de la Ley Federal del Derecho de Autor de México, que autoriza reproducir fragmentos de una obra con fines de crítica e investigación [40]. En cumplimiento de ello, el sistema indexó de esos materiales solo el título, la página y metadatos de la estructura del libro, que permitían recuperar información estructural de las lecciones sin almacenar una copia de su contenido, mientras que el Plan de Estudio y los Programas Sintéticos se indexaron con su texto completo.

3. Análisis y discusión de resultados

3.1 Comparación de planeaciones

Se compararon cuatro fuentes de planeaciones en seis grados de primaria, con un mismo tema por grado elegido por los docentes: la 1, generada con la aplicación por los docentes de la prueba piloto (uno por grado y dos en 6.º, promediadas); la 2, descargada sin modificar de cicloescolar.mx [41], un banco de unas 25 planeaciones por grado, sin personalizar y con anexos, elegida por su parecido temático con la 1; y la 3 y la 4, generadas sin RAG ni libros de texto indexados con Gemini 3.6 Flash y ChatGPT (GPT-5.6 Luna), en sus versiones gratuitas y chats, con un mismo prompt basado en los datos básicos de la 1. Todo se generó y evaluó el 4 de octubre de 2026. Un evaluador (Claude Sonnet 5.5, en una sola conversación) calificó las planeaciones, identificadas solo por número, de 1 a 10, con 12 criterios definidos por los autores junto con una docente en servicio. Cada calificación fue el promedio de tres revisiones ciegas, con diferencias de décimas, posteriormente se promedió el resultado de 3 evaluaciones contextualizadas. Los resultados de la primera prueba indicaron un promedio de 8.46 para la planeación 2, 7.94 para la 4, 7.90 para la 3 y 6.80 para la 1; tras contextualizar, de 7.85, 6.98, 6.78 y 7.12, respectivamente, y solo la 1 aumentó (Tabla 1 y Figura 13).

Tabla 1. Síntesis del desempeño de las cuatro planeaciones: calificación a ciegas y calificación tras contextualizar el origen de cada planeación (escala de 1 a 10), y perfil observado. Fuente: elaboración propia.

Planeación	A ciegas	Contextualizada	Perfil observado
1. Aplicación	6.80	7.12	La más personalizada y, según los docentes, de menor tiempo de elaboración; incluye RAG y libros de texto gratuitos (LTG), con referencias verificadas; sin anexos. Única cuya calificación aumentó al contextualizar el origen de cada planeación.
2. Banco de planeaciones	8.46	7.85	Completa y con anexos, pero limitada a unas 25 por grado y sin personalizar; el docente debe invertir más tiempo en adaptarla.
3. Gemini sin RAG	7.90	6.78	Sin RAG ni LTG; no se verifica si emplea los procesos de desarrollo de aprendizaje ni los demás recursos del programa. Parece adecuada en una lectura general, pero no se comprueba su ajuste a la NEM, que es lo que busca el RAG.
4. ChatGPT sin RAG	7.94	6.98	Sin RAG ni LTG; no se verifica si emplea los procesos de desarrollo de aprendizaje ni los demás recursos del programa. Parece adecuada en una lectura general, pero no se comprueba su ajuste a la NEM, que es lo que busca el RAG.

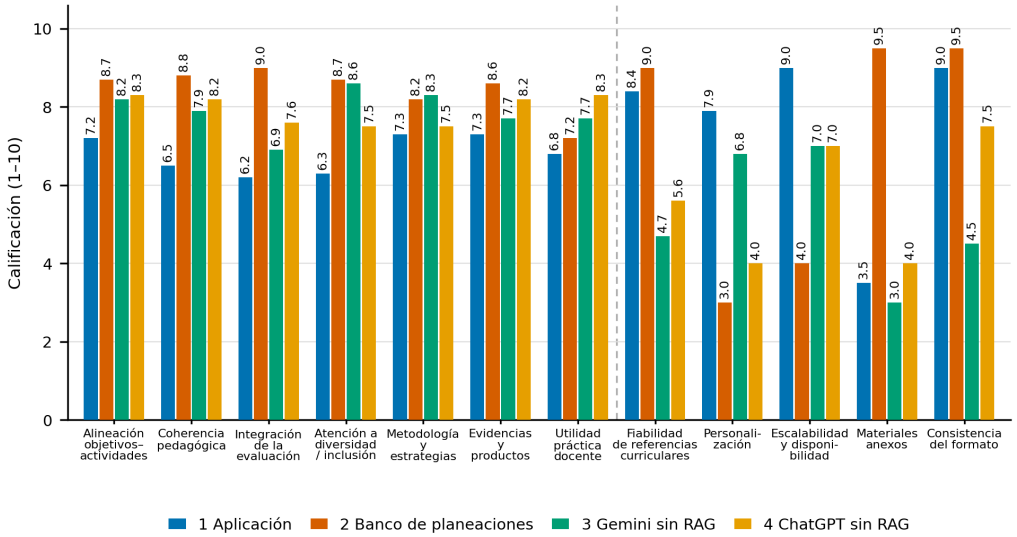


Figura 13. Calificación de las cuatro planeaciones en los 12 criterios evaluados (promedio de 1.º a 6.º, escala de 1 a 10); los cinco últimos se calificaron después de informar el origen de cada planeación. Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura, con resultados de la evaluación de las planeaciones.

3.2 Especificaciones de la comparación

La planeación 1 reunió la mayor personalización al docente y su grupo (7.9), una base curricular con RAG y libros de texto citados con página, verificada manualmente por los autores (fiabilidad de 8.4), y escalabilidad a cualquier tema y grado (9.0); además, se elabora en una aplicación y, según los docentes, en menos tiempo, dato que esta comparación no midió. Sus áreas de mejora son los anexos (3.5), la evaluación por niveles y una mayor precisión temporal.

La planeación 2 fue la más completa, con anexos (9.5) y referencias oficiales con página (9.0), pero su banco se limita a unas 25 planeaciones por grado y no está personalizada (3.0), por lo que el docente debe invertir tiempo adicional en adaptarla.

Las planeaciones 3 y 4 tuvieron una presentación completa y una estructura adecuada, pero sin RAG verificable ni libros de texto indexados no se garantiza su apego al programa vigente: la 3, por ejemplo, citó libros inexistentes. Además, se entregaron como texto sin formato (.txt), mientras que la 1 se entrega lista para imprimir.

3.3 Limitaciones de la comparación

La comparación es exploratoria. Se evaluó una planeación por fuente y grado (24 casos) con un solo evaluador, un LLM, que puede favorecer textos largos o estructurados [42]. Los 12 criterios, definidos por los autores junto con una docente en servicio, no tuvieron validación formal por jueces expertos. El anonimato fue parcial: la planeación 2 incluía los sellos del sitio, los formatos difirieron (PDF en las planeaciones 1 y 2, texto en la 3 y 4) y la numeración fue fija, lo que pudo generar sesgo de orden. Las condiciones tampoco fueron equivalentes: el banco no está personalizado y las planeaciones 3 y 4 se generaron en chats gratuitos, con modelo y configuración posiblemente distintos a los de la aplicación. Aun así, la planeación 1 superó a la 3 en la fiabilidad de las referencias curriculares (8.4 frente a 4.7), lo que respalda el aporte del RAG: sus citas fueron correctas, según la verificación manual de los autores, y los docentes participantes aprobaron la planeación generada (sección 3.6). Por ello, los resultados son ilustrativos y no evidencia de superioridad de alguna fuente.

3.4 Cobertura curricular

El corpus curricular para RAG integró documentos oficiales de la NEM, clasificados según su naturaleza y protección de derechos de autor. Los Programas Sintéticos y el Plan de Estudio se indexaron con texto completo, mientras que los libros de texto, del docente y material multigrado se procesaron solo como metadatos (título, página y estructura de las lecciones), conforme al artículo 148, fracción III, de la LFDA [40]. Esta distinción se reflejó en la arquitectura de ingesta y en Supabase, donde cada documento conservó una etiqueta que identificó su régimen de procesamiento: texto completo o

metadatos. Esto permitió verificar el tratamiento aplicado a cada documento sin inspeccionar su contenido. Un ejemplo de este registro se muestra en la Figura 14, donde el modo «solo_estructura» corresponde al tratamiento solo con metadatos y el campo «estado» indica el resultado del procesamiento del documento. En la revisión manual de las planeaciones que incluyeron libros de texto, las páginas referenciadas correspondieron a las lecciones citadas.

tipo_documento	nombre_logico	grado	campo_formativo	modo_rag	estado
multigrado	CARTOGRAFIA DE MEXICO Y EL MUNDO	0	NULL	solo_estructura	listo
multigrado	MEXICO GRANDEZA Y DIVERSIDAD	0	NULL	solo_estructura	listo
libro_texto	MULTIPLES LENGUAJES	1	Lenguajes	solo_estructura	listo
libro_texto	MULTIPLES LENGUAJES TRAZOS Y PALABRAS	1	Lenguajes	solo_estructura	listo
libro_texto	NUESTROS SABERES	1	Saberes y Pensamiento Científico	solo_estructura	listo
libro_texto	PROYECTOS COMUNITARIOS	1	De lo Humano y lo Comunitario	solo_estructura	listo
libro_texto	PROYECTOS DE AULA	1	Ética, Naturaleza y Sociedades	solo_estructura	listo
libro_texto	PROYECTOS ESCOLARES	1	De lo Humano y lo Comunitario	solo_estructura	listo
libro_texto	MULTIPLES LENGUAJES	2	Lenguajes	solo_estructura	error
libro_texto	NUESTROS SABERES	2	Saberes y Pensamiento Científico	solo_estructura	error

Figura 14. Registro de documentos en Supabase con su modo de procesamiento y estado. Fuente: elaboración propia, captura de Supabase.

3.5 Prueba de campo y validación con docentes

La prueba de campo se realizó con siete docentes en servicio, seis de una misma escuela primaria y uno de otra institución, todos de primaria (uno también de preescolar). Cinco de siete tenían más de diez años de experiencia, cinco dedicaban más de tres horas a una planeación (Figura 15) y cuatro habían usado antes una IA generativa. La familiaridad con aplicaciones móviles (promedio de 2.71) y la confianza en la IA (promedio de 2.57) fueron de bajas a moderadas en una escala de 1 a 5. Las principales preocupaciones fueron la inexactitud, la pérdida del criterio pedagógico y la falta de adaptación al grupo, señaladas cada una por cuatro de siete docentes.

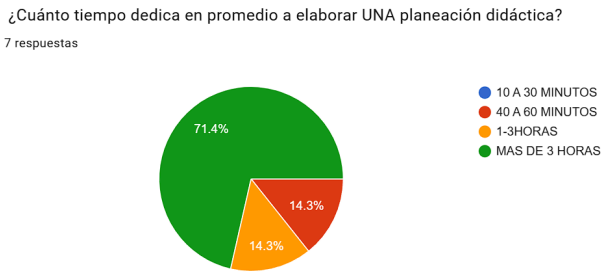


Figura 15. Tiempo dedicado a elaborar una planeación (n = 7). Fuente: elaboración propia, captura de la encuesta de inicio en Google Forms.

3.6 Usabilidad de la aplicación móvil

Los siete docentes generaron una planeación con la aplicación y la revisaron desde su experiencia profesional, valorando su aplicabilidad a su entorno y contexto escolar, su coherencia, y la existencia y paginación de las referencias citadas. Cuatro reportaron completar el flujo en menos de 5 minutos (Figura 16); el tiempo fue autorreportado.

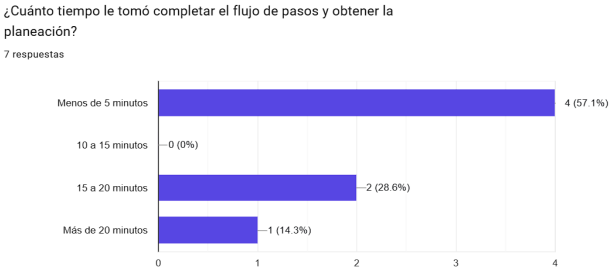


Figura 16. Tiempo para completar el flujo de la aplicación (n = 7). Fuente: elaboración propia, captura de la encuesta de usabilidad en Google Forms.

Los siete docentes calificaron con el valor máximo (5 de 5) que la aplicación fue fácil de usar y que la mayoría de los docentes aprendería a utilizarla rápidamente (Figura 17); seis lo hicieron también al valorar su seguridad al usarla, y el séptimo respondió 3. La planeación generada se consideró pedagógicamente pertinente y las actividades adecuadas para el grupo (seis docentes respondieron 5 y uno respondió 4), y los siete coincidieron en que la aplicación puede reducir el tiempo y el esfuerzo de planeación (Figura 18). Frente a su forma habitual de

planear, tres docentes la calificaron como mejor y cuatro como mucho mejor (Figura 19). Tres docentes marcaron «Sí» en el ítem de complejidad aunque calificaron con 5 la facilidad de uso, por lo que se interpretó como una posible inversión de la escala y el ítem no se analizó. Al preguntar por errores, datos inventados o inconsistencias, cinco docentes respondieron «Ninguno» y dos no respondieron; ningún docente reportó errores.

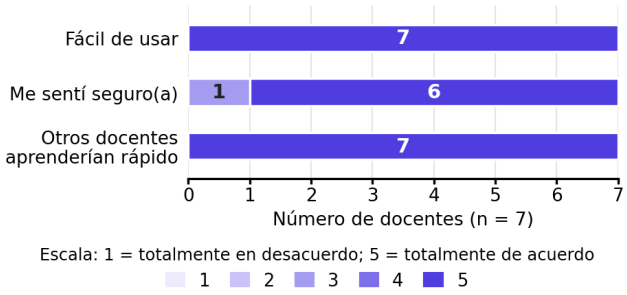


Figura 17. Distribución de respuestas sobre usabilidad (escala de 1 a 5, n = 7). Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura, con resultados de los formularios de Google Forms.

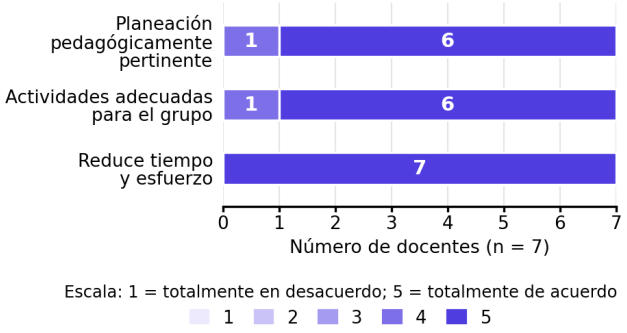


Figura 18. Distribución de respuestas sobre calidad percibida y reducción de tiempo (escala de 1 a 5, n = 7). Fuente: Elaboración propia con asistencia de inteligencia artificial (IA) para la edición y composición de la figura, con resultados de los formularios de Google Forms.

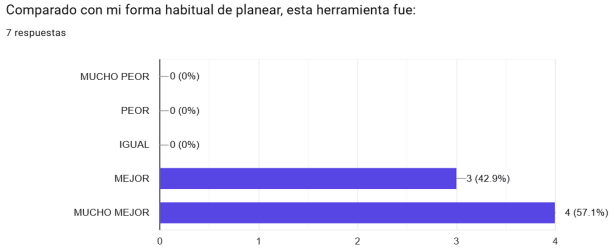


Figura 19. Comparación con la forma habitual de planear (n = 7). Fuente: elaboración propia, captura de la encuesta de usabilidad en Google Forms.

3.7 Comentarios y mejoras

En una conversación posterior a la encuesta de usabilidad, los docentes manifestaron que la aplicación integraba los procesos de desarrollo de aprendizaje y los Programas Sintéticos, que las planeaciones eran coherentes y que constituía una muy buena opción para elaborarlas, ya que reduce considerablemente el tiempo que dedican a planear sus actividades. Señalaron además su potencial a futuro. Se les explicó que era una aplicación en desarrollo y no un producto final, por lo que sus sugerencias son útiles para mejoras futuras.

En la pregunta abierta de la encuesta de usabilidad sobre qué cambiarían, agregarían o mejorarían de la aplicación (Figura 20), las respuestas con sugerencias fueron «Que incluya anexos» y «Agregar ejercicios»; las demás fueron «Nada», «Ninguno» y «Todo muy bien», y dos docentes no respondieron. La sugerencia de anexos coincide con la comparación, donde la planeación 2 los incluía y la 1 carece de ellos (sección 3.2). Estos comentarios, por provenir de siete participantes, se consideran indicativos y no generalizables.

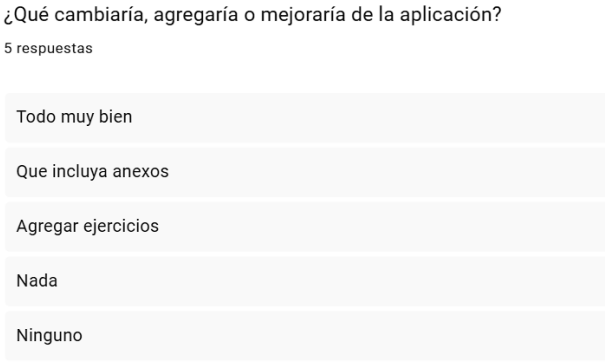


Figura 20. Respuestas abiertas sobre mejoras de la aplicación (5 respuestas). Fuente: elaboración propia, captura de la encuesta de usabilidad en Google Forms.

3.8 Limitaciones del sistema

La aplicación dependió de una única clave de API de Gemini, gestionada en el servidor, lo que evita exponerla en el cliente, pero es un punto único de falla ante suspensión o agotamiento de cuota. Se limitó el uso a 30 solicitudes diarias por docente. El sistema operó con niveles gratuitos de las API y del backend, cuyas cuotas restringen el número de solicitudes y de usuarios; atender a más usuarios requeriría planes de pago, claves o proveedores de respaldo y colas de solicitudes. Además, requiere internet y la prueba fue un piloto de siete

docentes, seis de una misma escuela, sin grupo de control, con datos autorreportados y solo en primaria.

3.9 Discusión respecto al estado del arte

Este trabajo se diferencia de los asistentes de IA educativa genéricos en que recupera contexto de documentos oficiales, con protección de derechos de terceros por diseño, en lugar de depender solo del conocimiento del modelo. Los estudios con ChatGPT sin anclaje curricular reportan planeaciones funcionales que requieren revisión docente [17]–[19], y los enfoques que combinan RAG con autocrítica se han evaluado frente a planeaciones reales [43]. Plataformas como Shiksha Copilot [12] o el prototipo para secundarias de Uganda [13] comparten el principio de anclaje curricular, pero, hasta donde se pudo revisar, no abordan la Nueva Escuela Mexicana. En México, cicloescolar.mx [41] ofrece un banco de material pedagógico con planeaciones conforme a la NEM 2022, pero no es una herramienta de IA generativa y su banco es limitado y sin personalización; este trabajo atiende esa brecha con planeaciones personalizadas y ancladas al currículo.

4. Conclusiones

Aplicación Docente es una alternativa viable para apoyar la planeación docente con IA, al integrar un RAG curricular con fuentes oficiales de la NEM. La revisión manual mostró congruencia curricular y paginación correcta en los libros citados. En la comparación exploratoria de cuatro fuentes en seis grados, cada una mostró un perfil distinto: la aplicación obtuvo los valores más altos en personalización y escalabilidad y fue la única cuya calificación aumentó al contextualizar (de 6.80 a 7.12), mientras que el banco obtuvo las más altas (8.46 y 7.85). Los docentes calificaron con el máximo la mayoría de los ítems de usabilidad y percibieron menor tiempo de planeación. Los resultados son exploratorios; las mejoras pendientes son los anexos, la evaluación por niveles y la precisión temporal.

Declaración sobre el uso de inteligencia artificial

Los autores declaran que se utilizaron herramientas de inteligencia artificial (IA) generativa para asistir en la corrección gramatical en inglés, la edición lingüística y la mejora de la expresión escrita del manuscrito, así como en la elaboración de los diagramas y gráficas de las figuras. Además, Gemini y ChatGPT generaron las planeaciones 3 y 4 de la comparación, respectivamente, y Claude Sonnet 5.5 calificó las planeaciones.

Referencias

[1] E. Kasneci et al., "ChatGPT for good? On opportunities and challenges of large language models for education," Learning and Individual Differences, vol. 103, art. 102274, 2023.

[2] S. Wang et al., "Large language models for education: A survey and outlook," arXiv preprint arXiv:2403.18105, 2024.

[3] B. Alhafni, S. Vajjala, S. Bannò, K. K. Maurya, and E. Kochmar, "LLMs in education: Novel perspectives, challenges, and opportunities," arXiv preprint arXiv:2409.11917, 2024.

[4] Z. Ji et al., "Survey of hallucination in natural language generation," ACM Computing Surveys, vol. 55, no. 12, pp. 1–38, 2023.

[5] L. Yan et al., "Practical and ethical challenges of large language models in education: A systematic literature review," arXiv preprint arXiv:2303.13379, 2023.

[6] Y. Zhang et al., "Siren's song in the AI ocean: A survey on hallucination in large language models," arXiv preprint arXiv:2309.01219, 2023.

[7] Y. Gao et al., "Retrieval-augmented generation for large language models: A survey," arXiv preprint arXiv:2312.10997, 2024.

[8] P. Lewis et al., "Retrieval-augmented generation for knowledge-intensive NLP tasks," in Proc. 34th Int. Conf. Neural Information Processing Systems (NeurIPS), 2020, pp. 9459–9474.

[9] MagicSchool AI. [Online]. Available: https://www.magicschool.ai. Accessed: Aug. 12, 2026.

[10] Eduaide.ai. [Online]. Available: https://www.eduaide.ai. Accessed: Aug. 12, 2026.

[11] Education Copilot. [Online]. Available: https://www.educationcopilot.com. Accessed: Oct. 2, 2026.

[12] D. Varuvel Dennison et al., "Shiksha Copilot: Teacher-AI collaboration for curating and customizing lesson plans in low-resource schools," Proc. ACM Hum.-Comput. Interact., vol. 10, no. 2, art. CSCW038, Apr. 2026, doi: 10.1145/3788074.

[13] S. Kloker, H. Bukoli, and T. Kateete, "New curriculum, new chance — Retrieval augmented generation for lesson planning in Ugandan secondary schools. Prototype quality evaluation," arXiv preprint arXiv:2408.07542, 2024.

[14] Secretaría de Educación Pública, "Acuerdo número 14/08/22 por el que se establece el Plan de Estudio para la educación preescolar, primaria y secundaria," Diario Oficial de la Federación, 19 de agosto de 2022. [Online]. Available: https://www.dof.gob.mx/nota_detalle.php?codigo=5661845&fecha=19/08/2022. Accessed: Sep. 30, 2026.

[15] Secretaría de Educación Pública, "Acuerdo número 08/08/23 por el que se establecen los Programas de Estudio para la educación preescolar, primaria y secundaria: Programas Sintéticos de las Fases 2 a 6," Diario Oficial de la Federación, 15 de agosto de 2023. [Online]. Available: https://www.dof.gob.mx/nota_detalle.php?codigo=5698665&fecha=15/08/2023. Accessed: Sep. 30, 2026.

[16] T. Zheng, W. Li, J. Bai, W. Wang, and Y. Song, "KnowShiftQA: How robust are RAG systems when textbook knowledge shifts in K-12 education?," in Proc. 63rd Annu. Meeting Assoc. Comput. Linguistics (Volume 2: Short Papers), 2025, arXiv:2412.08985.

[17] J. Jeon and S. Lee, "Large language models in education: A focus on the complementary relationship between human teachers and ChatGPT," Education and Information Technologies, vol. 28, no. 12, pp. 15873–15892, Dec. 2023.

[18] P. J. Kalenda, L. Rath, M. Abugasea Heidt, and A. Wright, "Pre-service teacher perceptions of ChatGPT for lesson plan generation," Journal

of Educational Technology Systems, vol. 53, no. 3, pp. 219–241, 2025.

[19] C. K. Lo, "What is the impact of ChatGPT on education? A rapid review of the literature," Education Sciences, vol. 13, no. 4, art. 410, 2023.

[20] G.-G. Lee and X. Zhai, "Using ChatGPT for science learning: A study on pre-service teachers' lesson planning," IEEE Transactions on Learning Technologies, vol. 17, 2024, arXiv:2402.01674.

[21] S. Gupta, R. Ranjan, and S. N. Singh, "A comprehensive survey of retrieval-augmented generation (RAG): Evolution, current landscape and future directions," arXiv preprint arXiv:2410.12837, 2024.

[22] W. Fan et al., "A survey on RAG meeting LLMs: Towards retrieval-augmented large language models," arXiv preprint arXiv:2405.06211, 2024.

[23] pgvector, GitHub repository. [Online]. Available: https://github.com/pgvector/pgvector. Accessed: Aug. 12, 2026.

[24] E. Marin, D. Perino, and R. Di Pietro, "Serverless computing: a security perspective," Journal of Cloud Computing, vol. 11, art. 69, 2022.

[25] L. Wei et al., "How far are app secrets from being stolen? A case study on Android," Empirical Software Engineering, 2025, arXiv:2501.07805.

[26] V. K. P. Budigi and S. C. Sirigiri, "Beyond similarity search: A unified data layer for production RAG systems," arXiv preprint arXiv:2605.03275, 2026.

[27] C. Shorten et al., "StructuredRAG: JSON response formatting with large language models," arXiv preprint arXiv:2408.11061, 2024.

[28] R. Qu, R. Tu, and F. S. Bao, "Is semantic chunking worth the computational cost?," in Findings of the Association for Computational Linguistics: NAACL 2025, 2025, arXiv:2410.13070.

[29] A. Kusupati et al., "Matryoshka representation learning," in Advances in Neural Information Processing Systems (NeurIPS), vol. 35, 2022, pp. 30233–30249.

[30] J. Lee et al., "Gemini Embedding: Generalizable embeddings from Gemini," arXiv preprint arXiv:2503.07891, 2025.

[31] C.-Y. Lin, L.-C. Wang, and S.-P. Chang, "Incremental checkpointing for fault-tolerant stream processing systems: A data structure approach," IEEE Transactions on Emerging Topics in Computing, vol. 10, no. 1, pp. 124–136, 2022.

[32] S. Troshin et al., "Control the temperature: Selective sampling for diverse and high-quality LLM outputs," arXiv preprint arXiv:2510.01218, 2025.

[33] P. Sahoo et al., "A systematic survey of prompt engineering in large language models: Techniques and applications," arXiv preprint arXiv:2402.07927, 2024.

[34] S. M. Bsharat, A. Myrzakhan, and Z. Shen, "Principled instructions are all you need for questioning LLaMA-1/2, GPT-3.5/4," arXiv preprint arXiv:2312.16171, 2023.

[35] K. Shuster, S. Poff, M. Chen, D. Kiela, and J. Weston, "Retrieval augmentation reduces hallucination in conversation," in Findings of ACL: EMNLP 2021, pp. 3784–3803, 2021.

[36] L. Huang et al., "Learning fine-grained grounded citations for attributed large language models," in Findings of the Association for Computational Linguistics: ACL 2024, 2024, arXiv:2408.04568.

[37] I. Kusmaryono, D. Wijayanti, and H. Maharani, "Number of response options, reliability, validity, and potential bias in the use of the Likert scale education and social science research: A literature review," International Journal of Educational Methodology, vol. 8, no. 4, pp. 625–637, 2022.

[38] M. Hyzy et al., "System usability scale benchmarking for digital health apps: Meta-analysis," JMIR mHealth and uHealth, vol. 10, no. 8, p. e37290, 2022.

[39] V. Schwind et al., "A scoping review of informed consent practices in human-computer interaction research," ACM TOCHI, vol. 32, no. 4, pp. 1–60, 2025.

[40] Cámara de Diputados del H. Congreso de la Unión, "Ley Federal del Derecho de Autor," Diario Oficial de la Federación, 24 de diciembre de 1996, última reforma publicada el 14 de mayo de 2026. [Online]. Available: https://www.diputados.gob.mx/LeyesBiblio/pdf_mov/Ley_Federal_del_Derecho_de_Autor.pdf

[41] CicloEscolar.mx, "Planeaciones didácticas de educación primaria." [Online]. Available: https://www.cicloescolar.mx. Accessed: Oct. 4, 2026.

[42] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," in Advances in Neural Information Processing Systems (NeurIPS), vol. 36, 2023.

[43] Y. Zheng et al., "Automatic lesson plan generation via large language models with self-critique prompting," in Artificial Intelligence in Education (AIED 2024), Commun. Comput. Inf. Sci., vol. 2150, 2024, pp. 163–178, doi: 10.1007/978-3-031-64315-6_13.